

GNNs para detección de siniestros de tránsito

Carmen Beatriz Salinas De la Vega
Universidad de la República
Montevideo, Uruguay
carmen.salinas@fing.edu.uy

Bruno Ottonelli
Universidad de la República
Montevideo, Uruguay
bruno.ottonelli@fing.edu.uy

Resumen—Este trabajo, motivado por el incremento año tras año de los accidentes de tránsito en Montevideo, propone un enfoque basado en GNNs para la predicción de siniestros. Para ello, se modela el flujo del Sistema de Transporte Metropolitano como un grafo, a partir de los datos abiertos que provee la Intendencia de Montevideo correspondientes al año 2022. Se representa la realidad con un grafo por hora, donde los nodos representan las paradas de ómnibus y las aristas la relación entre estas, indicando la congestión del tráfico por ella calculada a partir de las variaciones en los tiempos de viaje de los ómnibus. Para abordar el problema, se implementó un algoritmo de clasificación a nivel de grafo desde dos enfoques diferentes: predicción sobre grafos aislados y predicción basada en series temporales. Los resultados finales muestran que el enfoque basado en series temporales es el que tuvo mejor desempeño, alcanzando un valor de accuracy del 72 % frente a un 65 % obtenido por el primer enfoque, y superando el 62 % obtenido por el modelo base.

Index Terms—Graph Neural Networks, Data science, Machine Learning, Public Transportation, Graph Classification

I. MOTIVACIÓN

Según informes de Gestión y Estadística de Seguridad Vial llevados adelante por la Unidad Nacional de Seguridad Vial [2], la cantidad de siniestros de tránsito aumenta cada año alrededor de 5 %. Según se informa, en 2024 se registraron 21.597 siniestros de tránsito; en particular, siendo Montevideo el departamento que registra más siniestros cada año. Dados estos antecedentes, creemos que es de interés poder encontrar formas de poder predecir cuando podrían darse estos siniestros.

II. INTRODUCCIÓN AL PROBLEMA

El problema general de detección de siniestros de tránsito ha sido abordado desde hace mucho tiempo y desde distintos enfoques, desde la detección a partir de datos de cámaras en la vía pública [5] hasta la vinculación de accidentes con el estado del clima. En ocasiones anteriores, este problema ya fue abordado a partir de la utilización de teoría de grafos [4] [3], ya que este enfoque proporciona un modelo permite estructurar muy bien la dinámica de los flujos de transporte.

Dada la motivación descrita en la sección anterior, este problema busca modelar el flujo de tránsito en forma de grafos a partir de datos de flujo de transporte público urbano y vincularlo a los siniestros de tránsito, intentando detectar qué situaciones pueden determinar la existencia de un siniestro y predecir donde ocurrirá a partir de estas. Para ello se utilizaran los datos de carácter público que pertenecen a la Intendencia de Montevideo.

Este proyecto abordará el diseño y modelado del problema utilizando grafos, con el fin de ser capaces de detectar los siniestros. Dicho grafo, estaría constituido por las paradas de omnibus como nodos y aristas que lo relacionan indicando la congestión del tramo.

Se adjunta además un link al repositorio con el código generado durante el desarrollo del proyecto.

III. CONJUNTO DE DATOS

Los conjuntos de datos a utilizar se encuentran disponibles en el *Portal de Datos Abiertos de la Intendencia de Montevideo* [1]. En particular, se utilizarán tres conjuntos de datos distintos:

- Datos de siniestros de tránsito.
- Datos de viajes de transporte urbano.
- Datos de las paradas de ómnibus.

III-A. Análisis de datos

III-A1. Siniestros de tránsito: El conjunto de datos de siniestros de tránsito utilizado contiene únicamente registros del año 2022 (link: Base anual de personas lesionadas en siniestros de tránsito). Es necesario resaltar que este conjunto de datos contiene información de cada persona involucrada únicamente de siniestros que contaron con personas lesionadas, y no de la totalidad de los siniestros ocurridos durante ese año. Los datos que se registran en cada entrada y que a su vez son de interés en este estudio son:

- Fecha (DD-MM-AAAA): Día en que ocurre el siniestro de tránsito.
- Tipo de siniestro (string): Tipo de siniestro ocurrido, puede tomar el valor ATROPELLO DE ANIMALES / ATROPELLO DE PEATÓN / DESPISTE / CAÍDA / COLISIÓN ENTRE VEHÍCULOS / COLISIÓN CON OBSTÁCULO EN CALZADA.
- Día de la semana (string): Día de la semana en que ocurrió el siniestro.
- Hora (integer): Hora en que ocurrió el siniestro. Puede tomar valores enteros del 0 al 23.
- X (integer): Longitud de ubicación del siniestro de tránsito.
- Y (integer): Latitud de ubicación del siniestro de tránsito.

Se dejaron fuera de este proyecto otras características registradas en el conjunto de datos como: edad de la persona

lesionada, sexo de la persona lesionada, si contaba con cinturón o casco en el accidente, entre otras características que consideramos que no aportaban al objetivo del proyecto.

Este conjunto de datos cuenta con 7802 instancias, con la distribución según el tipo de siniestro que se muestra en la Figura 1. Dado este resultado y el enfoque de este proyecto, nos centramos principalmente en el tipo *COLISIÓN ENTRE VEHÍCULOS*, teniendo 5668 instancias en total.




Figura 1. Distribución de siniestros de tránsito en Montevideo según tipo de siniestro en el año 2022

Si además analizamos dónde se encuentran la mayoría de estos accidentes, se puede observar que, en su mayoría, se concentran en la zona urbana de Montevideo. Estos resultados pueden apreciarse tanto analíticamente, como se presenta en la Figura 2, como visualmente, como se aprecia en la representación geográfica de la Figura 3.




Figura 2. Cantidad de colisiones entre vehículos por zona en Montevideo el año 2022.




Figura 3. Ubicación de colisiones sobre el mapa de Montevideo a lo largo del año 2022.

III-A2. Viajes de ómnibus y paradas: El conjunto de datos que se utilizara para modelar el flujo del tránsito contiene los viajes realizados en los ómnibus del Sistema de Transporte Metropolitano (link: viajes-realizados). En este caso, nos restringimos al relevamiento realizado en el año 2022 para ser congruentes con el conjunto de datos obtenido de siniestros.

Como concepto general, este conjunto de datos tiene una entrada con información por cada viaje que realiza un pasajero. Dentro de los datos brindados, se seleccionaron solo aquellos que consideramos útiles o necesarios para el desarrollo del proyecto; siendo estos:

- Fecha : Fecha y hora en la cual se registra el tramo del viaje.
- Cantidad de pasajeros: Cantidad de personas que realizan el tramo.
- Código parada origen: Donde la persona se tomó el ómnibus.
- Línea de ómnibus.

Para poder ubicar geográficamente cada viaje, fue necesario cruzar esta información con la brindada en el conjunto de datos con información de las paradas de ómnibus (link:datos-paradas). En este último conjunto de datos se encuentran los siguientes atributos:

- Código de parada.
- Línea de ómnibus.
- Calle y esquina donde se encuentra la parada.
- X: Longitud de la ubicación de la parada.
- Y: Latitud de la ubicación de la parada.

III-B. Preprocesamiento de conjunto de datos

Dados los conjuntos de datos descritos en las secciones anteriores, se debe realizar un preprocesamiento de estos para poder crear el grafo deseado. Este preprocesamiento requiere tanto la selección de los conjuntos a utilizar, como la creación de conjuntos faltantes para tener una descripción completa de la situación. A continuación se presentan los procesamientos realizados a los conjuntos de datos originales.

III-B1. Delimitación del conjunto de datos: Debido a que el conjunto de datos de viajes cuenta con cantidad inmanejable de instancias, fue necesario reducir el conjunto a utilizar a un mes en particular. Para ello tomamos en cuenta la distribución de siniestros por mes presentada en la Figura 4. Dada la distribución de siniestros por mes, se decidió optar por septiembre dado que es uno de los meses que presenta más colisiones entre vehículos. Dado un mes, también se puede analizar la distribución de colisiones entre vehículos por hora para el mes seleccionado (Figura 5).




Figura 4. Distribución de colisiones entre vehículos por mes en Montevideo en el año 2022.




Figura 5. Distribución de colisiones entre vehículos por hora en Montevideo en el mes de septiembre del año 2022.

Por otro lado, dada la cantidad de paradas de ómnibus, que luego representaríamos como nodos, se planteó reducir el problema a la predicción en alguna región particular de Montevideo donde la densidad de siniestros fuera relativamente alta. Posteriormente descartamos esta idea ya que, si bien había zonas que registraban una alta cantidad de siniestros durante el año, al filtrar por día o por hora no había ninguna zona a la que pudiéramos restringirnos y que consideráramos que la cantidad de datos de siniestros era suficiente como para entrenar un modelo.

Análogo a esta idea, se planteó la posibilidad de restringir la cantidad de nodos a simplemente las paradas pertenecientes a unas cuantas líneas de ómnibus representativas, pero este enfoque agravaría aún más los problemas presentados para el filtro por zona.

III-B2. Dificultades encontradas y conjunto de datos faltante: Originalmente, para estimar la congestión, se pensaba utilizar como base otro conjunto de datos disponibilizado por la intendencia con los datos teóricos de cada línea y frecuencia, con sus respectivos horarios y recorridos, pero este no contaba con los datos suficientes para poder ser cruzado con los otros conjuntos de datos que habíamos seleccionado, por lo que tuvimos que buscar nuevas soluciones. La solución encontrada a este problema fue generar este conjunto a partir de cálculos realizados sobre el conjunto de viajes para así poder estimar dichos horarios que usar como referencia.

Para generar este nuevo conjunto de datos, se toma el horario promedio en que la línea de ómnibus pasa por una parada determinada, espaciando 1 hora entre cada medida para obtener medidas más robustas. En la Figura 6 se muestra la secuencia seguida.

Para poder generar el recorrido de cada línea y así poder definir que aristas estarían relacionadas entre sí, también fue necesario generarlo a partir del conjunto de datos de viajes. Dicho esquema de procesamiento se muestra en la Figura 7.

III-B3. Otros preprocesamientos necesarios: Además de los mencionados, otros preprocesamientos menores fueron necesarios para poder trabajar con los datos brindados. Algunos de los datos presentaban datos dañados en determinados caracteres, provocando que no fuesen legibles o filtrables, como, por ejemplo, letras con tildes o fechas con formato no estándar.

Finalmente, para poder crear el dataset previo a crear el




Figura 6. Diagrama de generación del conjunto de datos de horarios teóricos.




Figura 7. Diagrama de generación del conjunto de datos de recorridos de líneas de ómnibus.

grafo, se agruparon y dividieron los datos por hora. De este modo, todos los siniestros se encasillaron dentro de un horario al igual que los viajes, que también fueron divididos dentro de cada hora para poder operar de manera más sencilla.

IV. GRAFO

Al tratarse de datos geográficos, con la definición de cada uno de los conjuntos de datos como se hizo, hace que sea posible representar la realidad utilizando un grafo. En esta sección se presentará la construcción del grafo a representar y se analizarán características del mismo.

IV-A. Definición del grafo

Para representar la realidad se plantea un grafo no dirigido con paradas de ómnibus como nodos y aristas correspondientes

a cuales paradas se relacionan por estar incluidas en los recorridos de cada línea de transporte.

Para poder asociar los siniestros a los grafos, los nodos de cada grafo de cada hora disponen de una característica que cuenta la cantidad de siniestros sucedidos cerca de dicha parada; y donde cada siniestro se asigna a una única parada.

Por lo tanto, cada nodo tendrá como *características*:

- La posición geográfica de la parada (*pos*).
- La cantidad de siniestros cerca de esa parada (*num_accidents*). Se define como medida de cercanía la distancia euclídea.
- El identificador de parada según el sistema original de viajes (*stop_id*).

En cuanto a las aristas, Cada una de ellas contendrá como peso una medida de congestión en ese tramo del recorrido. Dicha congestión en un tramo se mide como la diferencia entre el horario al que efectivamente pasó el ómnibus y el horario estimado teórico en minutos. Es decir, $w_{arista} = T_{real} - T_{teórico}$.

Por ejemplo, si desde la parada A a la B al omnibus le lleva 15 minutos, pero en la realidad le llevó 19, entonces el peso de la arista que une los nodos correspondientes a dichas paradas es 4.

Como se mencionó en secciones previas, dado que los valores de los atributos del grafo descrito varía con el tiempo, se construyo un grafo por hora para cada uno de los 30 días de septiembre, dando como resultado un conjunto de 720 grafos junto a sus marcas de tiempo, con 4611 nodos y 14060 aristas cada uno.

A modo ilustrativo, en las Figuras Figura 8 y Figura 9 se muestran los grafos obtenidos para el día 01/09/2022 a las 10:00 AM y a las 11:00 PM. En ellos se puede observar el grafo en su totalidad y como se ven los accidentes de tránsito a distintos momentos del día; donde a las 10 de la mañana (Figura 8) se tienen 3 siniestros (nodos rojos), mientras que a las 11 de la noche (Figura 9) no se registró ninguno.

V. PREDICCIÓN DE SINIESTROS

Como se adelantó en secciones previas, el objetivo del proyecto consiste en predecir si un grafo particular contendrá un siniestro o no. Debido a la naturaleza del problema, este presenta clases altamente desbalanceadas. Originalmente se pensó realizar la predicción a nivel de nodos, pero esto solo exageraría aún más dicho desbalance, por lo que se optó por generar etiquetas a nivel de grafos y realizar la predicción de esta manera.

Para implementarlo, se atacó el problema desde dos enfoques diferentes: como predicción sobre grafos aislados y como serie temporal. Ambos enfoques se entrenaron sobre una misma arquitectura pero cambiando la relación entre los grafos que ve a la entrada y lo que debe predecir en la salida.

La arquitectura usada en el modelo se representa en la Figura 10, y consta de tres capas *TAGConv* para que el modelo entienda las distintas situaciones a nivel local en los nodos, seguidas de una capa *Global Pooling* para condensar la información recopilada de en cada uno de ellos en un único




Figura 8. Grafo construido para el día 1 de septiembre de 2022 a las 10:00 AM.




Figura 9. Grafo construido para el día 1 de septiembre de 2022 a las 11:00 PM.

vector a nivel de grafo. A la salida, se cuenta finalmente con un clasificador compuesto por una capa *lineal* para bajar la dimensionalidad, una de *Dropout* para regularización y una *ReLU* para la no linealidad, previo a la ultima capa *lineal* de la salida que es la que efectivamente produce la clasificación.

Además, para poder evaluar el desempeño de los modelos implementados, se aprovechó la particularidad de que las clases están desbalanceadas para generar un modelo base que siempre predijera la etiqueta de la clase mayoritaria y así tener una referencia para calificar sus rendimientos.

V-A. Predicción de grafos aislados

Este enfoque consiste en tomar cada grafo como un dato aislado, sin tener en cuenta su temporalidad. El modelo deberá entender las características que representan un grafo con acci-




Figura 10. Esquema de la arquitectura del modelo utilizado en los algoritmos.

dentes y clasificarlo. Para este modelo se dividió el conjunto de datos con 720 grafos de manera aleatoria en 3 conjuntos, contando con 70 % para entrenamiento (504 grafos), 15 % para validación y 15 % para test (108 grafos en cada uno).

Otra precaución que se tomó fue eliminar de los nodos la característica que indica cuántos accidentes cercanos a ellos hubo. Básicamente, mantener esta característica en los nodos sería darle indirectamente la respuesta, y el modelo entendería rápidamente cómo conseguir una puntuación perfecta.

Los resultados de este modelo pueden verse en la Tabla I y en la matriz de confusión de la Figura 11, donde puede observarse que no consiguió grandes resultados, apenas pudiendo superar la marca obtenida por el modelo base.

Model	Accuracy
GNN	0.65
Baseline	0.62

Tabla I

COMPARACIÓN DE LOS RESULTADOS ENTRE EL MODELO BASE Y EL MODELO ENTRENADO, PARA EL ENFOQUE DE PREDICCIÓN SOBRE GRAFOS AISLADOS.

Analizando toda la situación luego de estos resultados, este bajo rendimiento puede deberse a la poca variación que presentan los grafos entre sí; ya que, además de mantenerse constantes los nodos y aristas por la naturaleza de los mismos, los pesos de estas no suelen variar demasiado en gran parte de las horas del día. Es posible que aplicando una función sobre




Figura 11. Matriz de confusión en el conjunto de test para el modelo con el enfoque de predicción sobre grafos aislados.

los pesos para amplificar las variaciones, se podría lograr un mejor rendimiento."

V-B. Predicción con series temporales

El enfoque basado en series temporales se basa en pasarle una serie de grafos al modelo, para que este intente predecir si en la hora siguiente a ellos habrá o no un siniestro.

A diferencia del modelo anterior, la continuidad temporal de los datos juega un rol importante, por lo que para este modelo se dividió el conjunto de datos en las mismas proporciones de entrenamiento, validación y test, pero, en vez de realizarse de manera aleatoria, se dividió cronológicamente.

El modelo se entrenó haciendo que pueda ver datos de la hora anterior para predecir la actual; y con esto logró superar tanto al modelo base como al modelo del primer enfoque. Los resultados de este experimento pueden verse en la Tabla II y en la matriz de confusión de la Figura 12. Dado estos resultados, podrían hacerse experimentos de extender la ventana temporal de los datos y así tal vez detectar nuevas dinámicas que podrían mejorar aún más los resultados.

Model	Accuracy
GNN	0.72
Baseline	0.62

Tabla II

COMPARACIÓN DE LOS RESULTADOS ENTRE EL MODELO BASE Y EL MODELO ENTRENADO, PARA EL ENFOQUE BASADO EN SERIES TEMPORALES.

VI. TRABAJO FUTURO Y NUEVAS IDEAS

A partir de los resultados obtenidos durante el desarrollo de este trabajo, se proponen las siguientes variantes y experimentos para dar continuidad al proyecto.

En primer lugar, se plantea ampliar la serie temporal del segundo modelo. Incrementar la ventana de tiempo del estudio




Figura 12. Matriz de confusión en el conjunto de test para el modelo con el enfoque basado en series temporales.

podría permitir capturar posibles comportamientos que se pueden dar a mayor plazo y así tal vez obtener un mejor desempeño.

Como segunda propuesta de nuevos experimentos, se plantea un cambio en la manera en la que se asignan los accidentes de tránsito a las paradas. En nuestro enfoque original, tomamos la distancia euclídea a las paradas como manera de identificar la ubicación de dicho siniestro en el grafo, pero esto no siempre es la mejor manera de representar la realidad. Un ejemplo de esto es que un accidente se asocie a una parada cercana, pero que haya ocurrido en una calle que circula en sentido distinto (por ejemplo, que un accidente en Bulevar Artigas se asocie a una parada en General Flores). En estos casos, el vehículo pertenecía a un "flujo distinto", por lo que este nuevo enfoque podría ser asignar estos accidentes a aristas en vez de paradas, o considerar la calle en la que estos se ubican (dato existente en el dataset).

VII. CONCLUSIONES

Luego de completadas todas las etapas del proyecto, podemos concluir que se logró moldear el problema para ser resuelto en base a grafos y construir una serie de estos que cumplieran con los requisitos del problema, superando gran parte de las dificultades que traían consigo los conjuntos de datos utilizados.

También se aplicaron los conocimientos del curso para estudiarlos y construir modelos de predicción basados en GNN con distintos enfoques, superando los resultados del modelo base planteado.

REFERENCIAS

- [1] Intendencia de Montevideo. Portal de datos abiertos de montevideo (ckan). <https://ckan.montevideo.gub.uy/>. Accedido: 2025-11-14.
- [2] Unidad Nacional de Seguridad Vial (UNASEV). Quintoinforme de gestión y estadística de seguridad vial, 2025. Consultado el 14 de noviembre de 2025.

- [3] Guangyin Jin, Yuxuan Liang, Yuchen Fang, Zezhi Shao, Jincai Huang, Junbo Zhang, and Yu Zheng. Spatio-temporal graph neural networks for predictive learning in urban computing: A survey, 2023.
- [4] Lei Li, Yaowen Dou, and Jiacheng Zhou. Traffic accident detection based on multimodal knowledge graphs. In *2023 5th International Conference on Robotics, Intelligent Control and Artificial Intelligence (RICAI)*, pages 644–647, 2023.
- [5] Ziyi Zhou. Traffic accident detection based on yolov11. In *2024 IEEE 2nd International Conference on Electrical, Automation and Computer Engineering (ICEACE)*, pages 363–369, 2024.